

ANÁLISIS COMPETITIVO DE POKÉMON TCG



Nombre: Juan Felipe Vallejo Quintero

Máster Data Analytics The Power MBA

1. Introducción

Para este proyecto he elegido analizar datos relacionados con Pokémon Trading Card Game, también conocido como Pokémon TCG. La elección se debe a mi interés personal por Pokémon y a que los datos disponibles permiten estudiar cartas, jugadores, torneos y tipos de mazo desde distintos puntos de vista.

El objetivo principal es analizar la presencia de cartas y arquetipos de mazos en torneos registrados entre 2011 y 2023. También se busca comprobar si los mazos más utilizados son los que consiguen mejores resultados y observar cómo ha cambiado el entorno competitivo con el paso de los años.

Para llevar a cabo el proyecto se han utilizado dos conjuntos de datos procedentes de Kaggle. Después de limpiar y transformar los datos, ambos conjuntos se han unido para crear un archivo final. El análisis se ha realizado con Python y Pandas, mientras que el dashboard se ha desarrollado con Power BI.

Las principales preguntas que se intentan responder son las siguientes:

- ¿Qué cartas aparecen en un mayor número de mazos?
- ¿Cuáles son los arquetipos más utilizados?
- ¿Qué arquetipos presentan una mayor proporción de resultados Top 8?
- ¿Cómo ha cambiado el número de mazos registrados a lo largo del tiempo?
- ¿Cómo se distribuyen los torneos entre las diferentes regiones?
- ¿Existe alguna diferencia entre los jugadores que alcanzan el Top 8 y el resto?

2. Fuentes de datos

Para cumplir el requisito de trabajar con dos fuentes distintas se han descargado dos conjuntos de datos de Kaggle.

2.1. Datos de torneos

El primer conjunto contiene información sobre mazos utilizados en torneos de Pokémon TCG entre 2011 y 2023.

Fuente:

<https://www.kaggle.com/datasets/enriccogemha/pokemon-tcg-all-tournaments-decks-2011-2023>

El archivo original contiene 114.291 filas y 26 columnas. Cada fila representa una carta incluida en el mazo de un jugador dentro de un torneo. Entre sus columnas se encuentran:

- Nombre e identificador de la carta.

- Número de copias utilizadas.
- Tipo de carta y tipo de energía.
- Nombre del arquetipo.
- Jugador y país del jugador.
- Posición final.
- Torneo, categoría, país y región.
- Año, mes y día del torneo.
- Rotación competitiva.

Este conjunto no incluye cartas de Energía. Los tipos de carta disponibles son Pokémon y Entrenador.

2.2. Catálogo de cartas

El segundo conjunto contiene un catálogo general de cartas de Pokémon TCG publicadas entre 1999 y 2023.

Fuente:

<https://www.kaggle.com/datasets/adampq/pokemon-tcg-all-cards-1999-2023>

El archivo contiene 17.172 filas y 29 columnas. Incluye información como:

- Identificador y nombre de la carta.
- Expansión y serie.
- Fecha de publicación.
- Artista.
- Tipo y subtipo.
- Puntos de salud.
- Ataques y habilidades.
- Rareza.
- Debilidades y resistencias.
- Legalidad y marca de regulación.

Este catálogo contiene varias ediciones de una misma carta. Por ejemplo, el nombre Pikachu aparece en 98 registros diferentes.

3. Herramientas utilizadas

Las herramientas utilizadas han sido:

- Python para realizar el análisis.
- Pandas para cargar, limpiar, transformar y unir los datos.
- NumPy para algunos cálculos y para crear variables.
- Matplotlib para generar las visualizaciones del análisis exploratorio.
- Jupyter Notebook desde Visual Studio Code para organizar el trabajo.
- Power BI Desktop para construir el dashboard.
- GitHub para publicar el proyecto final.

4. Exploración inicial

Después de cargar los archivos se revisaron sus dimensiones, tipos de datos, valores nulos y posibles duplicados.

En el archivo de torneos se encontraron 84 filas completamente duplicadas. Estas filas se eliminaron para evitar contar varias veces la misma información. Después de la eliminación, el conjunto quedó formado por 114.207 registros.

El catálogo de cartas no contenía filas duplicadas exactas.

También se encontraron valores ausentes en varias columnas. No todos los nulos tenían el mismo significado, por lo que se trataron de forma diferente según la información de cada campo.

5. Limpieza y transformación

5.1. Tratamiento de valores ausentes

La columna `energy_type_card` tenía 71.790 valores ausentes. Se comprobó que todos correspondían a cartas de Entrenador, que no tienen un tipo de energía propio. Estos valores se sustituyeron por “No aplica”.

Los valores ausentes de las siguientes columnas se sustituyeron por “Desconocido”:

- Nombre del arquetipo.
- Región del torneo.
- Rotación válida en el torneo.

Los precios ausentes se mantuvieron como nulos. Un precio desconocido no significa que la carta tenga un precio de cero, por lo que sustituirlos habría introducido información incorrecta.

Los identificadores de arquetipo ausentes también se conservaron como nulos.

5.2. Preparación de las fechas

Las columnas de año, mes y día se combinaron para crear fecha_torneo.

No se encontraron fechas inválidas. El periodo registrado comienza el 13 de agosto de 2011 y termina el 14 de octubre de 2023.

5.3. Comprobación de valores numéricos

Se revisaron las cantidades de cartas, las posiciones finales y los precios.

No se encontraron:

- Cantidades de cartas iguales o inferiores a cero.
- Posiciones de torneo iguales o inferiores a cero.
- Precios negativos.
- Repeticiones de la misma carta para el mismo jugador y torneo.

La cantidad de copias de una carta se encuentra entre una y cuatro, lo que resulta coherente con la estructura habitual de un mazo competitivo.

5.4. Preparación de la unión

Los dos conjuntos no podían unirse directamente por identificador porque utilizaban sistemas de identificación diferentes. Por esta razón, la unión se realizó mediante el nombre de la carta.

Se creó una columna auxiliar llamada nombre_union. Los nombres se pasaron a minúsculas y se eliminaron los espacios situados al principio o al final.

El catálogo tenía 17.172 identificadores únicos, pero solamente 3.946 nombres distintos. Si se hubiera unido directamente por nombre, cada registro de torneo se habría repetido por todas las ediciones existentes de la carta.

Para evitarlo, el catálogo se agrupó por nombre y se calcularon tres campos:

- Número de entradas diferentes en el catálogo.
- Número de expansiones diferentes.
- Número de artistas conocidos.

De esta manera, cada nombre quedó representado por una sola fila.

5.5. Corrección de nombres

En una primera unión se obtuvo correspondencia para el 99,16 % de los registros. Al revisar los nombres sin correspondencia se detectaron algunas diferencias de escritura.

Una de las diferencias más frecuentes era el símbolo de diamante utilizado en determinadas cartas. En el archivo de torneos aparecía como $\diamond$, mientras que en

el catálogo aparecía como ◇. Ambos símbolos se normalizaron conservando la distinción frente a las versiones sin diamante.

También se aplicaron algunas equivalencias comprobadas manualmente:

- Battle Compressor.
- Target Whistle.
- Head Ringer.
- Robo Substitute.
- Flabebe.

Después de repetir la unión se consiguió correspondencia para 114.202 de los 114.207 registros, lo que supone un 99,9956 %.

Solo quedaron cinco registros sin correspondencia:

- Tres registros de Palace Book.
- Dos registros de Pokemon Card Gym Medal.

Estos registros se conservaron y las columnas procedentes del catálogo se mantuvieron como nulas.

5.6. Resultado final

Después de la limpieza y la unión se obtuvo un conjunto final con 114.207 filas y 32 columnas. Posteriormente se añadió id_mazo, llegando a 33 columnas.

Este identificador se creó combinando el identificador del torneo y el identificador del jugador. De esta forma se puede reconocer cada mazo sin confundir las diferentes cartas que contiene.

También se creó una tabla resumida con una sola fila por mazo. Esta tabla contiene 5.003 filas y 16 columnas, y se utiliza principalmente en Power BI.

6. Análisis descriptivo

El conjunto final contiene:

- 114.207 registros de cartas.
- 5.003 mazos.
- 2.656 jugadores diferentes.
- 133 torneos.
- 1.707 identificadores de carta.
- 1.323 nombres de carta diferentes.

- 377 arquetipos de mazo.


6.1. Cartas con mayor presencia

Para calcular la presencia de una carta se contó una sola vez por mazo, aunque el jugador utilizara varias copias.

Las cartas más presentes fueron:

1. Ultra Ball, presente en 3.694 mazos, un 73,84 %.
2. Boss's Orders, presente en 3.411 mazos, un 68,18 %.
3. Escape Rope, presente en 2.422 mazos, un 48,41 %.
4. Nest Ball, presente en 2.032 mazos, un 40,62 %.
5. Battle VIP Pass, presente en 2.007 mazos, un 40,12 %.

Estos resultados indican qué cartas son más frecuentes dentro de los registros analizados. No indican que su utilización aumente directamente la probabilidad de ganar.




6.2. Evolución anual

La cobertura del conjunto no es igual en todos los años. En 2011 solo aparecen nueve mazos, mientras que en 2023 aparecen 3.060.

Durante 2020 y 2021 se observa una reducción importante. El conjunto contiene 121 mazos en 2020 y solamente 25 en 2021. Esta bajada coincide con el periodo de suspensión de gran parte de las competiciones presenciales durante la pandemia.

Los porcentajes de esos años deben interpretarse con precaución porque se calculan con pocas observaciones. Por ejemplo, que Boss's Orders aparezca en el 100 % de los mazos de 2021 no significa que estuviera presente en todos los mazos competitivos del mundo, sino en todos los mazos incluidos en esta muestra.



6.3. Arquetipos más utilizados


El arquetipo con mayor presencia es Lugia Archeops:

- 814 mazos.
- 578 jugadores distintos.
- Presencia en 53 torneos.
- 16,27 % de todos los mazos.

Después aparecen:

- Lost Zone Box, con 437 mazos y un 8,73 %.
- Mew Genesect, con 306 mazos y un 6,12 %.
- Gardevoir, con 274 mazos y un 5,48 %.
- Fusion Mew, con 206 mazos y un 4,12 %.

La diferencia entre el número de mazos y el número de jugadores indica que algunos jugadores utilizaron el mismo arquetipo en más de un torneo.



6.4. Presencia en el Top 8

Se creó la variable `top_8`, que toma el valor 1 cuando un mazo termina entre las ocho primeras posiciones y 0 en el resto de casos.


Para comparar arquetipos se estableció un mínimo de 30 mazos registrados. Así se evita destacar un mazo con un porcentaje alto basado en uno o dos casos.

Entre los arquetipos que cumplen ese mínimo, los porcentajes más elevados fueron:

- Mewtwo & Mew, con un 54,29 %.
- Buzzwole Lycanroc, con un 34,29 %.
- Zacian ADP, con un 29,55 %.
- Palkia Inteleon, con un 27,38 %.
- Zapdos, con un 23,53 %.

Los arquetipos más utilizados no coinciden necesariamente con los que presentan una mayor proporción de posiciones Top 8. Popularidad y rendimiento son dos aspectos diferentes.

Este porcentaje tampoco representa una tasa de victorias, ya que los datos no contienen el resultado individual de cada partida.




6.5. Evolución de los arquetipos

El arquetipo más representado cambia a lo largo del periodo analizado. Algunos ejemplos son:

- Yveltal Garbodor en 2014.
- Night March en 2015 y 2016.
- Zoroark Lycanroc en 2018.
- Pikachu & Zekrom en 2019.
- Zacian ADP en 2020 y 2021.
- Lugia Archeops en 2022 y 2023.

En 2023 aparecen 680 mazos de Lugia Archeops. La cifra es muy superior a la de los primeros años, aunque parte de la diferencia se debe a que 2023 tiene una cobertura mucho mayor.



7. Análisis estadístico

7.1. Distribución de las posiciones

Las posiciones finales de los 5.003 mazos presentan los siguientes resultados:

- Media: 47,24.
- Mediana: 35.
- Desviación estándar: 42,02.
- Posición mínima: 1.
- Posición máxima: 193.

La distribución es asimétrica hacia la derecha. Muchos mazos se concentran en las primeras posiciones, mientras que existe una cola larga hacia posiciones más elevadas.

Por este motivo, la mediana es útil para describir la posición habitual. Se encuentra menos afectada por los valores extremos que la media.

7.2. Comparación entre Top 8 y resto de participantes

También se comparó el historial de puntuación de los jugadores mediante la variable `all_time_score`.

En los mazos que alcanzaron el Top 8:

- La media de `all_time_score` fue 147,05.
- La mediana fue 61.

En los mazos que no alcanzaron el Top 8:

- La media fue 90,44.
- La mediana fue 30.

Los jugadores que llegaron al Top 8 presentan una puntuación histórica superior dentro de los datos analizados. Esto muestra una asociación entre el historial del jugador y su posición final, pero no permite afirmar que una variable sea la causa directa de la otra.

7.3. Intervalo de confianza

De los 5.003 mazos registrados, 934 alcanzaron el Top 8. Esto representa un 18,67 %.

Se calculó un intervalo de confianza del 95 % para esta proporción. El resultado se encuentra entre el 17,59 % y el 19,75 %.

Este intervalo expresa la incertidumbre de la proporción observada dentro de la muestra. No representa la probabilidad individual de que cualquier mazo alcance el Top 8.

8. Desarrollo del dashboard en Power BI

Para construir el dashboard se importaron los dos archivos procesados:

- `pokemon_tcg_completo.csv`
- `pokemon_tcg_mazos.csv`

La tabla completa contiene una fila por carta incluida en un mazo. La tabla resumida contiene una sola fila por mazo.

Las tablas se relacionaron mediante `id_mazo`. La relación tiene cardinalidad uno a varios:

- `pokemon_tcg_mazos` representa el lado uno.
- `pokemon_tcg_completo` representa el lado varios.

Esta relación permite analizar tanto los datos generales de cada mazo como las cartas que contiene.

8.1. Medidas utilizadas

Se crearon las siguientes medidas:

Total Mazos = `COUNTROWS(pokemon_tcg_mazos)`

Total Torneos = `DISTINCTCOUNT(pokemon_tcg_mazos[id_tournament])`

Total Jugadores = `DISTINCTCOUNT(pokemon_tcg_mazos[id_player])`

Mazos Top 8 = SUM(pokemon_tcg_mazos[top_8])

Porcentaje Top 8 = AVERAGE(pokemon_tcg_mazos[top_8])

8.2. Contenido del dashboard

En la parte superior se muestran cinco indicadores:

- Total de mazos: 5.003.
- Total de torneos: 133.
- Total de jugadores: 2.656.
- Mazos Top 8: 934.
- Porcentaje Top 8: 18,67 %.

El dashboard incluye los siguientes gráficos:

Mazos más utilizados

Presenta los cinco arquetipos con mayor cantidad de mazos. Permite comprobar rápidamente el dominio de Lugia Archeops dentro de los datos.

Evolución anual de mazos

Muestra el número de mazos disponibles en cada año. Se observa la bajada de 2020 y 2021 y el fuerte aumento de registros en 2022 y 2023.

Porcentaje Top 8 de los mazos más utilizados

Compara la proporción de resultados Top 8 entre los cinco arquetipos más frecuentes. Dentro de ese grupo, Fusion Mew presenta el porcentaje más alto, con un 16,02 %.

Torneos por región

Muestra la distribución de los 133 torneos entre las regiones disponibles. Parte de los torneos aparecen con región desconocida, por lo que se ha mantenido esta categoría visible.

También se añadieron filtros de año, región y categoría. Estos filtros permiten actualizar las tarjetas y los gráficos para analizar periodos o grupos concretos.

Para el diseño se utilizó un fondo gris claro, tarjetas blancas y una combinación de azul y amarillo relacionada con la imagen de Pokémon. Se intentó mantener una distribución sencilla para facilitar la lectura.



9. Principales conclusiones

El análisis permite observar que las cartas más presentes suelen ser cartas de utilidad general que pueden incluirse en muchos arquetipos. Ultra Ball y Boss's Orders destacan claramente sobre el resto.

Lugia Archeops es el arquetipo más frecuente del conjunto, con 814 mazos. Sin embargo, ser el más utilizado no significa tener la mayor proporción de apariciones en el Top 8.

Los resultados muestran una diferencia entre popularidad y rendimiento. Algunos arquetipos menos frecuentes presentan porcentajes Top 8 superiores a los mazos más utilizados.

También se observa que los jugadores cuyos mazos alcanzan el Top 8 tienen un all_time_score mayor, tanto en media como en mediana.

La evolución anual está muy condicionada por la cobertura de los datos. Los años 2022 y 2023 contienen muchos más registros que los primeros años. La reducción de 2020 y 2021 coincide además con el periodo de la pandemia.

En total, el 18,67 % de los mazos analizados terminó dentro del Top 8. El intervalo de confianza del 95 % sitúa esta proporción entre el 17,59 % y el 19,75 %.

10. Limitaciones

El proyecto presenta algunas limitaciones que deben tenerse en cuenta:

- Los datos no incluyen todos los torneos celebrados en cada año.
- La cobertura temporal es muy desigual.
- El año 2023 concentra 3.060 de los 5.003 mazos.

- No se dispone de los resultados de cada partida.
- La entrada en el Top 8 no equivale a una tasa de victorias.
- Algunos torneos no tienen una región identificada.
- El catálogo se ha unido mediante nombres normalizados y no mediante el identificador exacto de la edición utilizada.
- La información del catálogo describe todas las ediciones disponibles hasta 2023, no necesariamente la edición concreta utilizada en cada torneo.
- Cinco registros no encontraron correspondencia en el catálogo.

A pesar de estas limitaciones, los datos permiten estudiar la presencia de cartas, la popularidad de los arquetipos, la evolución temporal y algunos indicadores relacionados con las posiciones finales.

11. Posibles mejoras

Como ampliación futura se podrían incorporar resultados individuales de partidas. Esto permitiría calcular tasas de victoria reales y realizar comparaciones más precisas entre arquetipos.

También sería útil conseguir una cobertura más homogénea de torneos y añadir información sobre enfrentamientos, rondas, formato y número total de participantes.

Otra mejora sería identificar la edición exacta de cada carta utilizada en el torneo, en lugar de trabajar solamente con el nombre.

12. Archivos generados

El proyecto incluye:

- Dos conjuntos de datos originales.
- Un conjunto completo procesado con 114.207 filas y 33 columnas.
- Una tabla procesada con 5.003 mazos.
- Un notebook con la limpieza y el análisis.
- Cinco visualizaciones creadas con Matplotlib.
- Un dashboard interactivo en Power BI.
- El presente informe.
- Un archivo README con la explicación general del repositorio.